

02 CV Selection Error Rate vs Sample Size

Aileen Tao

Goal

Data are simulated under a **linear** truth. For each sample size on a grid from 50 to 10,000 (step 50), we run 10-fold cross-validation for a **linear** model and a **degree-3 polynomial** model, pick the model with lower mean CV MSE, and record whether CV incorrectly chose the polynomial. The **CV selection error rate** is the fraction of 1,000 Monte Carlo replications where polynomial wins.

Simulation settings

Table 1: Simulation and CV settings for analysis 02.

setting	value
seed	2026
K	10
Monte Carlo replications	1000
per n	
Sample sizes (grid)	50, 100, ..., 10000 (step 50)
beta0	1
beta1	2
sigma	4
poly_degree	3
truth	linear: $y = \text{beta0} + \text{beta1} * x + \text{eps}$
selection rule	Choose poly3 if mean CV MSE strictly lower than linear; else linear

CV error summary by sample size

Table 2: Monte Carlo mean selection-error rate (truth is linear; error = poly chosen) and approximate MC standard error.

n	error_rate	mc_se
50	0.150	0.01129
100	0.151	0.01132
150	0.153	0.01138
200	0.154	0.01141
250	0.159	0.01156
300	0.158	0.01153
350	0.162	0.01165
400	0.155	0.01144
450	0.151	0.01132
500	0.154	0.01141
550	0.158	0.01153
600	0.166	0.01177
650	0.151	0.01132
700	0.141	0.01101
750	0.145	0.01113
800	0.131	0.01067
850	0.176	0.01204
900	0.150	0.01129
950	0.157	0.01150
1000	0.155	0.01144
1050	0.146	0.01117
1100	0.147	0.01120
1150	0.151	0.01132
1200	0.146	0.01117
1250	0.134	0.01077
1300	0.145	0.01113
1350	0.156	0.01147
1400	0.159	0.01156
1450	0.145	0.01113
1500	0.158	0.01153
1550	0.170	0.01188
1600	0.162	0.01165
1650	0.151	0.01132
1700	0.124	0.01042
1750	0.164	0.01171

n	error_rate	mc_se
1800	0.155	0.01144
1850	0.157	0.01150
1900	0.132	0.01070
1950	0.158	0.01153
2000	0.166	0.01177
2050	0.179	0.01212
2100	0.131	0.01067
2150	0.166	0.01177
2200	0.146	0.01117
2250	0.163	0.01168
2300	0.158	0.01153
2350	0.160	0.01159
2400	0.156	0.01147
2450	0.152	0.01135
2500	0.163	0.01168
2550	0.136	0.01084
2600	0.156	0.01147
2650	0.147	0.01120
2700	0.146	0.01117
2750	0.159	0.01156
2800	0.138	0.01091
2850	0.146	0.01117
2900	0.160	0.01159
2950	0.151	0.01132
3000	0.152	0.01135
3050	0.137	0.01087
3100	0.156	0.01147
3150	0.154	0.01141
3200	0.161	0.01162
3250	0.138	0.01091
3300	0.168	0.01182
3350	0.158	0.01153
3400	0.155	0.01144
3450	0.140	0.01097
3500	0.138	0.01091
3550	0.166	0.01177
3600	0.160	0.01159
3650	0.137	0.01087
3700	0.153	0.01138
3750	0.146	0.01117
3800	0.130	0.01063

n	error_rate	mc_se
3850	0.164	0.01171
3900	0.144	0.01110
3950	0.134	0.01077
4000	0.159	0.01156
4050	0.134	0.01077
4100	0.145	0.01113
4150	0.156	0.01147
4200	0.132	0.01070
4250	0.152	0.01135
4300	0.130	0.01063
4350	0.153	0.01138
4400	0.152	0.01135
4450	0.144	0.01110
4500	0.145	0.01113
4550	0.156	0.01147
4600	0.174	0.01199
4650	0.158	0.01153
4700	0.137	0.01087
4750	0.170	0.01188
4800	0.161	0.01162
4850	0.161	0.01162
4900	0.163	0.01168
4950	0.157	0.01150
5000	0.146	0.01117
5050	0.150	0.01129
5100	0.154	0.01141
5150	0.157	0.01150
5200	0.173	0.01196
5250	0.153	0.01138
5300	0.150	0.01129
5350	0.157	0.01150
5400	0.142	0.01104
5450	0.172	0.01193
5500	0.148	0.01123
5550	0.158	0.01153
5600	0.150	0.01129
5650	0.152	0.01135
5700	0.158	0.01153
5750	0.141	0.01101
5800	0.148	0.01123
5850	0.158	0.01153

n	error_rate	mc_se
5900	0.153	0.01138
5950	0.149	0.01126
6000	0.138	0.01091
6050	0.149	0.01126
6100	0.142	0.01104
6150	0.163	0.01168
6200	0.164	0.01171
6250	0.155	0.01144
6300	0.171	0.01191
6350	0.162	0.01165
6400	0.137	0.01087
6450	0.147	0.01120
6500	0.148	0.01123
6550	0.151	0.01132
6600	0.151	0.01132
6650	0.160	0.01159
6700	0.153	0.01138
6750	0.157	0.01150
6800	0.164	0.01171
6850	0.159	0.01156
6900	0.161	0.01162
6950	0.163	0.01168
7000	0.134	0.01077
7050	0.133	0.01074
7100	0.156	0.01147
7150	0.144	0.01110
7200	0.142	0.01104
7250	0.160	0.01159
7300	0.147	0.01120
7350	0.162	0.01165
7400	0.168	0.01182
7450	0.162	0.01165
7500	0.174	0.01199
7550	0.146	0.01117
7600	0.156	0.01147
7650	0.156	0.01147
7700	0.138	0.01091
7750	0.161	0.01162
7800	0.148	0.01123
7850	0.137	0.01087
7900	0.147	0.01120

n	error_rate	mc_se
7950	0.154	0.01141
8000	0.140	0.01097
8050	0.143	0.01107
8100	0.149	0.01126
8150	0.160	0.01159
8200	0.139	0.01094
8250	0.150	0.01129
8300	0.158	0.01153
8350	0.158	0.01153
8400	0.149	0.01126
8450	0.155	0.01144
8500	0.165	0.01174
8550	0.143	0.01107
8600	0.137	0.01087
8650	0.136	0.01084
8700	0.145	0.01113
8750	0.145	0.01113
8800	0.146	0.01117
8850	0.152	0.01135
8900	0.134	0.01077
8950	0.156	0.01147
9000	0.172	0.01193
9050	0.168	0.01182
9100	0.148	0.01123
9150	0.146	0.01117
9200	0.170	0.01188
9250	0.138	0.01091
9300	0.128	0.01056
9350	0.149	0.01126
9400	0.170	0.01188
9450	0.162	0.01165
9500	0.138	0.01091
9550	0.152	0.01135
9600	0.169	0.01185
9650	0.140	0.01097
9700	0.146	0.01117
9750	0.160	0.01159
9800	0.149	0.01126
9850	0.136	0.01084
9900	0.155	0.01144
9950	0.175	0.01202

n	error_rate	mc_se
10000	0.146	0.01117

CV error rate vs sample size




Figure 1: CV selection error rate as a function of sample size (ribbon = MC SE band, clipped to $[0, 1]$).

Conclusion

Under a linear data-generating process, the rate at which 10-fold CV prefers the more flexible polynomial varies with sample size; the curve summarizes this across the grid of $\mathbf{n}$.